

# 딥러닝 기반 차량 차선 변경 구간 분류 모델

AI빅데이터학과 20231459 황혜린

## 1. 서론

본 보고서는 SUMO(Simulation of Urban Mobility)에서 생성된 차량 궤적 데이터를 활용하여 차량의 차선 변경 구간을 분류하는 딥러닝 모델을 설명한다. 모델은 차량의 시계열 데이터(위치, 속도, 가속도)를 입력으로 받아 차선 변경 구간을 0(직진), 1, 2, 3 의 네 가지 클래스로 예측한다. 본 문서에서는 데이터 처리, 모델 구조, 학습 과정, 성능 평가를 중심으로 모델을 상세히 기술한다.

## 2. 데이터 처리

### 2.1 데이터셋 개요

데이터는 csv 형식으로 제공되며, 학습(1,229대), 검증(175대), 테스트(352대) 데이터로 구성된다. 각 데이터는 최대 60초의 시계열 정보를 포함하며, 주요 피쳐는 다음과 같다.

- time\_step: 주행 시점(초)
- vehicle\_id: 차량 고유 식별자
- position\_y: 차량의 y 좌표
- speed: 차량 속도
- acceleration: 차량 가속도
- change\_section: 차선 변경 구간(0, 1, 2, 3)

#### 2.1. 전처리 과정

전처리 과정 효율적인 모델 학습을 위해 다음과 같은 전처리를 수행하였다

- 정규화: position\_y, speed, acceleration 피쳐를 StandardScaler로 표준화하여 평균 0, 표준편차 1로 변환
- 시계열 패딩: 차량 별 시계열 길이를 60으로 통일하기 위해, 부족한 부분은 0으로 패딩
- 데이터셋 구성: TrajectoryDataset 클래스를 통해 차량 별 데이터를 그룹화하고, DataLoader로 배치 크기 32의 데이터 로더 생성.

## 3. 모델 구조

### 3.1. 모델 개요

제안된 모델은 Temporal Convolutional Network(TCN), Bidirectional GRU(BiGRU), Attention 메커니즘을 결합한 아키텍처로 설계되었다. 이 모델은 시계열 데이터의 지역적 패턴과 장기 의존성을 효과적으로 학습하며, 중요한 시점에 주목하여 분류 성능을 향상시킨다.

### 3.2. 구성요소

- Temporal Convolutional Network (TCN):
  - 입력 차원: 3(position\_y, speed, acceleration)
  - 채널: [64, 128, 256]의 3개 TemporalBlock
  - 각 블록은 1D 컨볼루션, 배치 정규화, ReLU 활성화, 드롭아웃(0.2), 잔차 연결로 구성
  - Dilation( $2^i$ )을 통해 넓은 수용 영역을 확보
- Bidirectional GRU (BiGRU):
  - TCN 출력(256차원)을 입력으로 받아, 128차원의 hidden state를 가진 양방향 GRU 적용
  - 시계열의 순방향 및 역방향 정보를 학습하여 장기 의존성 포착
- Attention 메커니즘:
  - BiGRU 출력(256차원)에 대해 소프트맥스 기반의 어텐션 가중치 계산
  - 중요한 시계열 포인트를 강조하여 최종 표현(256차원) 생성
- 분류기:
  - Attention 출력(256차원)을 64차원으로 축소 후, ReLU 활성화 및 드롭아웃(0.2) 적용
  - 최종 4차원 출력(클래스 0, 1, 2, 3)을 위한 선형 레이어

## 4. 학습과정

### 4.1. 학습설정

모델 학습은 다음과 같은 설정으로 수행되었다.

- 손실 함수: CrossEntropyLoss
- 옵티마이저: Adam (학습률  $10^{-3}$ )
- 에포크 수: 20
- 배치 크기: 32
- 디바이스: CUDA 지원 GPU (또는 CPU)
- 시드 고정: 재현성을 위해 시드 42로 설정

### 4.2. 학습절차

- 학습 루프:  
각 에포크에서 학습 데이터를 배치 단위로 처리하며, 손실을 계산하고 역전파를 수행
- 검증:  
매 에포크 후 검증 데이터로 모델을 평가하여 F1-Score를 기준으로 최적 모델 저장
- 최적 모델 로드:  
학습 완료 후 F1-Score가 가장 높은 모델을 로드하여 테스트 예측 수행

## 5. 성능평가

### 5.1. 평가지표

모델은 Accuracy, Precision, Recall, F1-Score를 기준으로 평가되었다. F1-Score는 클래스 불균형을 고려한 주요 지표로 사용되었으며, macro 평균을 통해 클래스별 성능을 균형 있게 평가하였다.

### 5.2. 결과

검증데이터에 대한 평가결과는 학습 과정에서 출력되었으며, 최적 모델은 테스트 데이터에 대해 예측을 수행하여 submission.csv로 저장되었다. 제출 파일은 vehicle\_id 와 예측된 change\_section으로 구성되며, 테스트 데이터의 차량 ID 순서에 맞게 정렬 되었다.

## 6. 결론

본 모델은 TCN, BiGRU, Attention을 결합하여 차량 차선 변경 구간 분류 문제를 효과적으로 해결하였다. TCN은 지역적 패턴을, BiGRU는 장기 의존성을, Attention은 중요한 시점에 주목하여 높은 분류 성능을 달성하였다. 향후 개선 방향으로 더 깊은 TCN 레이어 추가, 하이퍼파라미터 최적화, 또는 추가 피처 (예: 차량 간 거리) 도입을 고려할 수 있다.